Entrega 1 - Arquitectura, conclusiones y consideraciones

Javier Alejandro Gómez, Alejandra Guerrero, Diego Alejandro Peña, Juan Ignacio Arbeláez

{ja.gomez1003, a.guerrero10, da.pena20, ji.arbelaez}@uniandes.edu.co

Desarrollo de soluciones cloud - MINE

Universidad de los Andes, Bogotá, Colombia

Fecha de presentación: febrero 24 de 2023

Tabla de contenido

1. Introducción

En el presente documento se expone la arquitectura implementada para generar una aplicación web en Flask, la cual permita la compresión de archivos por medio de peticiones HTTP y utilizando un enfoque de procesamiento asíncrono. También se presentan las consideraciones que se tuvieron en cuenta en el desarrollo de este proyecto, teniendo en cuenta que con esta aplicación se busca a futuro aplicar los conceptos de escalabilidad, una de las características principales de los ambientes en nube.

El código y la documentación de este proyecto se pueden consultar en los siguientes enlaces:

- Repositorio GitHub: https://github.com/aguerrero10/Desarrollo-cloud-grupal
- Documentación de Postman: https://documenter.getpostman.com/view/13843294/2s93CPrY2y

El proyecto se implementó ejecutando las siguientes actividades que se identificaron en la fase de entendimiento del problema planteado:

1. Comprensión del problema descrito en el enunciado del proyecto
2. Preparación del servidor web: AWS EC2, Python y librerías, paths, entorno virtual, entre otros.
3. Preparación del servidor de base de datos AWS RDS y del motor PostgreSQL
4. Desarrollo en Flask de los servicios que permiten crear un usuario e iniciar sesión
5. Desarrollo en Flask de los servicios que permiten crear una tarea de compresión, consultarla, eliminarla y descargar su archivo original y comprimido
6. Creación y documentación de los escenarios de prueba en Postman
7. Construcción de la lógica de compresión de un archivo
8. Construcción del proceso asíncrono usando Celery y Redis
9. Desarrollo de la capa de presentación usando HTML, CSS y Javascript
10. Pruebas y revisión del funcionamiento global de la solución
11. Documentación de la arquitectura implementada

2. Arquitectura planteada

En este trabajo, se ha desarrollado una arquitectura robusta y escalable para la gestión de datos masivos que utiliza los siguientes componentes: base de datos PostgreSQL en servicio AWS RDS, Flask, servicios REST con JSON y apoyados en un servidor Linux Ubuntu Server 22.04 LTS en una máquina AWS EC2 para la capa de presentación.

El servicio RDS de AWS permite tener una base de datos PostgreSQL disponible y en una máquina diferente a donde se encuentra la aplicación Flask, lo que permite tener un mejor desempeño ante un alto número de solicitudes.

Flask, por su parte, fue utilizado para desarrollar la aplicación web y proporcionar una interfaz amigable y accesible para los usuarios. La arquitectura de Flask permite una fácil integración con otros componentes de la aplicación, provee un patrón de desarrollo MVC (Modelo Vista Controlador), lo que hizo posible una gestión eficiente de la presentación de los datos.

Por último, se utilizaron servicios REST con JSON para integrar la capa de datos y permitir una comunicación flexible y eficiente entre los componentes de la aplicación. Con esto se separa la aplicación web en el servidor presentación, del componente de data y procesamiento que posiblemente se pueda ir a una infraestructura distribuida que en futuros ejercicios sea utilizada.

De acuerdo con lo anterior, en la siguiente imagen se presenta el diagrama de despliegue de la aplicación web creada para la compresión de archivos con procesamiento asíncrono.

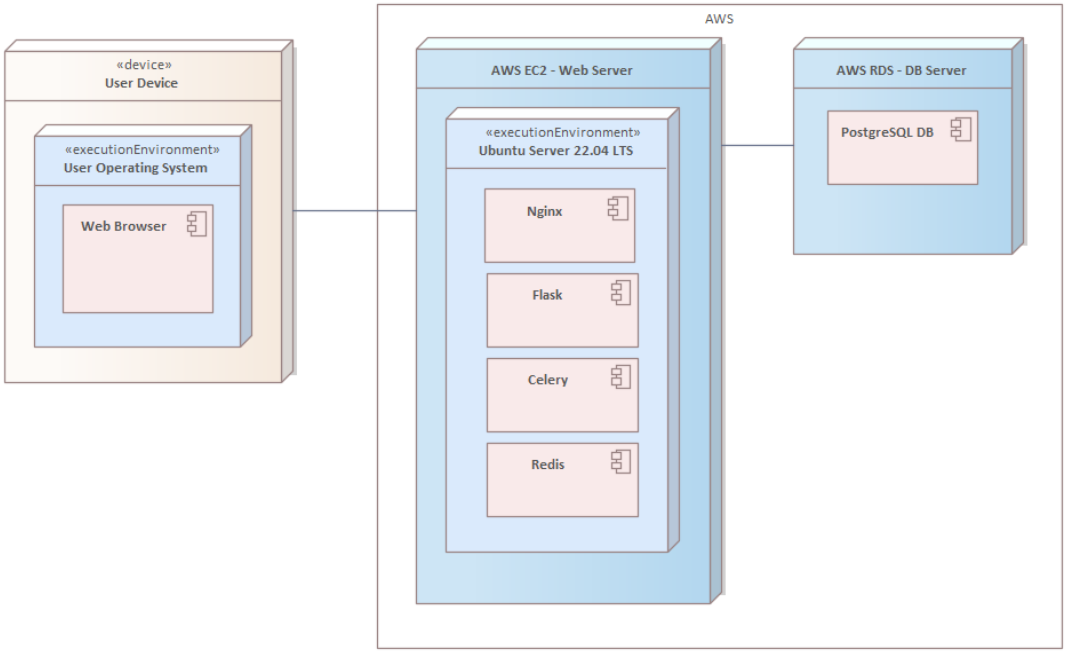

Figura 1. Diagrama de despliegue

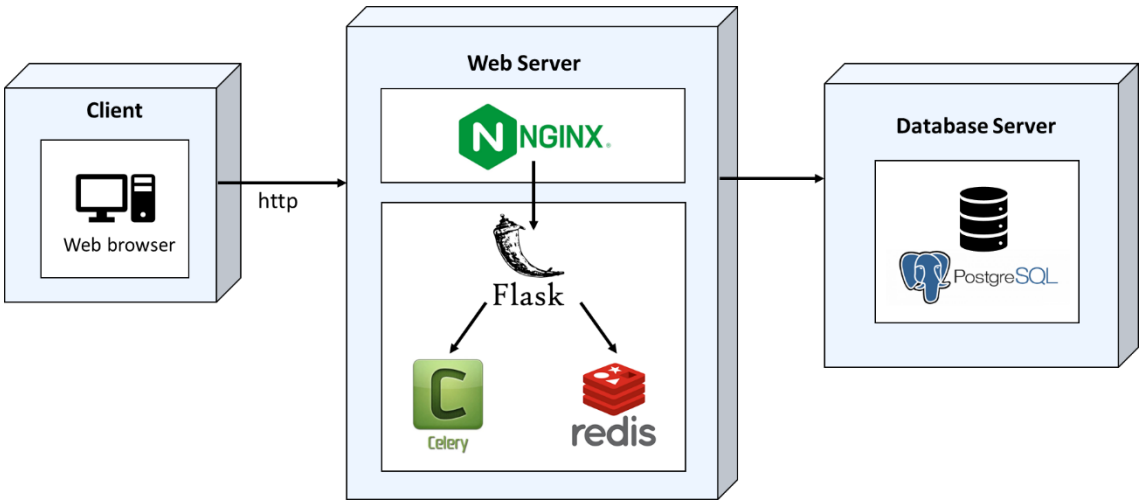

Figura 2. Diagrama de implementación

Como se evidencia en el diagrama de despliegue, la aplicación utiliza dos servidores para su funcionamiento: un servidor de base de datos Postgres desplegado sobre AWS RDS, y un servidor web sobre Ubuntu Server que expone los servicios requeridos y contiene la lógica de negocio, los cuales se implementaron usando el framework Flask, una cola de tareas Redis y un broker Celery. El cliente accede a los servicios de la aplicación por medio de peticiones HTTP.

Por otro lado, la lógica de negocio (backend) y la base de datos siguen el modelo de datos que se muestra en el siguiente diagrama:

Diagrama de clases

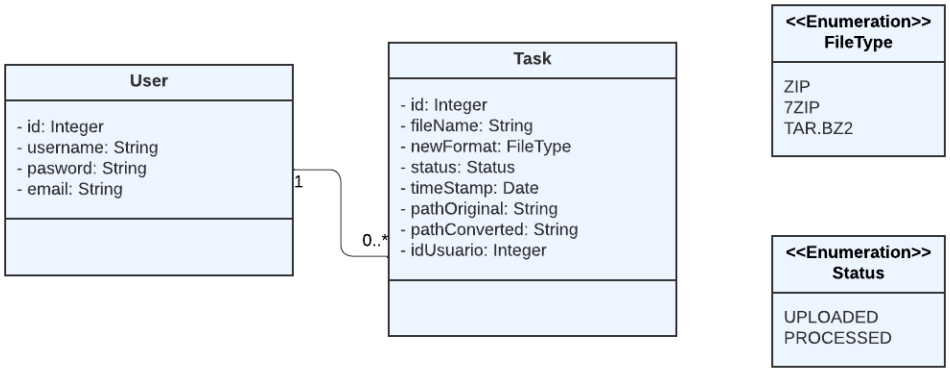

Es decir, el modelo de datos se compone de la entidad Usuario la cual se compone de sus datos básicos y puede o no tener múltiples tareas de compresión de archivos. Por otra parte, la entidad tarea tiene los datos del archivo a comprimir, su estado y tipo de archivo de archivo de compresión, modeladas con una enumeración.

Respecto a la capa de presentación, se implementó una interfaz de usuario con dos pantallas como se muestra a continuación.

Pantalla 1: permite el registro del usuario e inicio de sesión

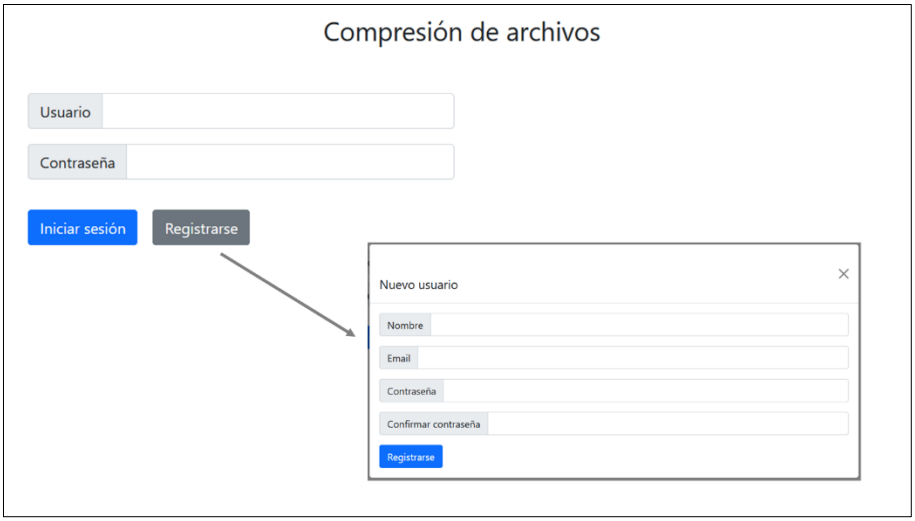

Pantalla 2.1: permite consultar las tareas de compresión de archivos o eliminarlos

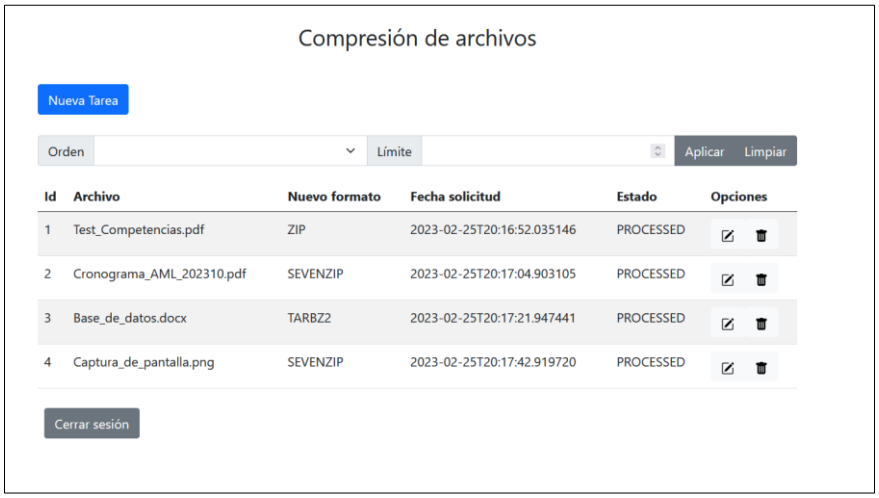

Pantalla 2.2: también permite crear tareas de compresión de archivos

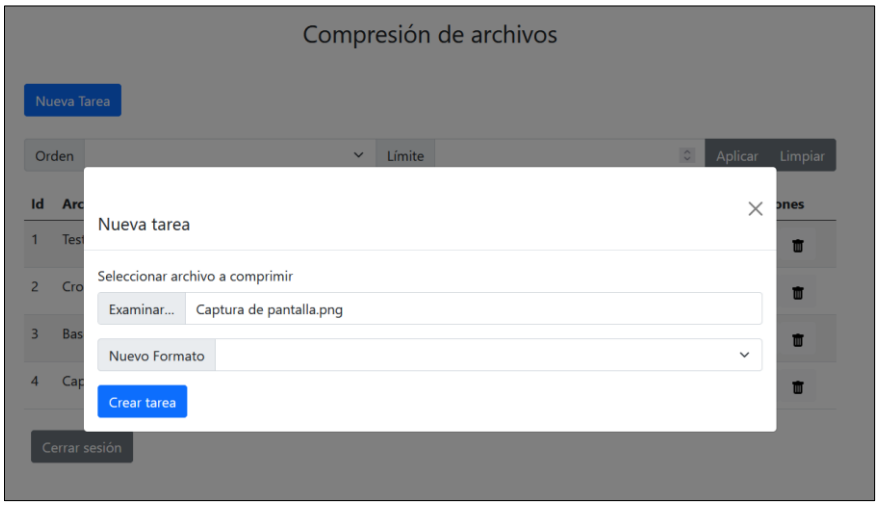

Pantalla 2.3: y permite la descarga del archivo original y comprimido

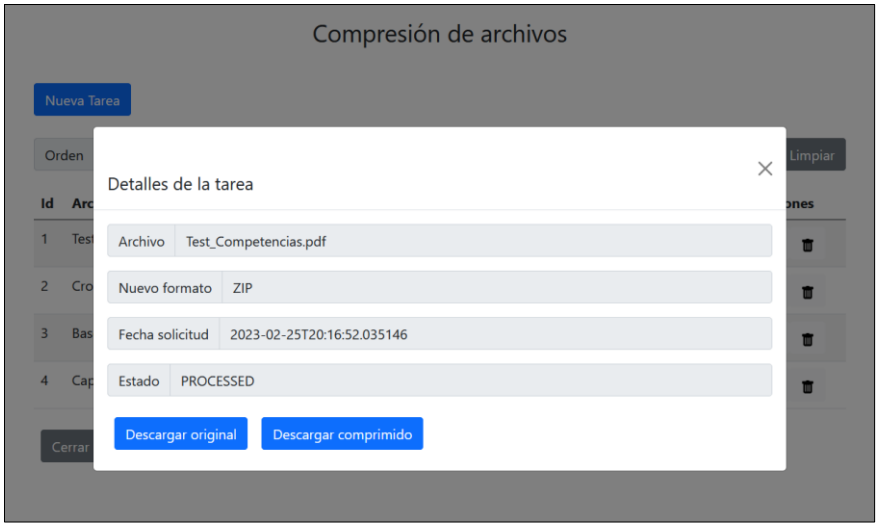

3. Instrucciones para la ejecución del entorno

Para iniciar la ejecución del entorno de la aplicación es necesario primero tener instalado Python en la máquina, es posible instalar Python usando Bash en la maquina con *sudo apt-get install python3.6.* A continuación, se debe instalar un ambiente virtual en el directorio base, en el cual se encuentra el archivo de requerimientos *requirements.txt.* Después de activar el ambiente virtual con *source {Nombre ambiente virtual]/bin/activate*, se deben instalar todas las librerías que usará la aplicación web, estas librerías y su versión se encuentran en *requirements.txt* por lo que al usar *pip install –m requirements.txt* se instalan todas las librerías necesarias en la aplicación web. Esta es la primera consola que debe estar activada, en la que se ejecuta la aplicación de Flask

Se activa una nueva ventana de la consola para correr comandos bash y esta ventana se usará para correr la instancia de Redis, esta instancia se corre con *redis-server –port 6360.* Este comando se utiliza para crear la instancia de Redis en el puerto 6360. En el archivo de tasks.py se define el puerto 6360 como el puerto en el que va a estar el broker de la aplicación de Celery

En este punto ya tenemos la instancia de Redis que se encarga de la cola de tareas y que se conecta con la aplicación de Celery en el puerto 6360 y necesitamos iniciar la aplicación de Flask que se encuentra que podemos activar en la primera terminal, en la cual tenemos el ambiente virtual activado. Debemos estar en la carpeta *"./backend/falskr"* y usar el comando Flask run para iniciar la aplicación de Flask. La aplicación de Flask inicia la instancia de la aplicación de Celery cuando el *worker* de Celery sea inicializado.

Ahora bien, abrimos una nueva ventana de la consola para iniciar la aplicación de Celery, para su ejecución debemos estar ubicados dentro del directorio "*./backend/flaskr"* y tener el ambiente virtual instalado previamente activado. Para iniciar la aplicación de Celery usamos el comando *celery –A tasks worker –l info.* Este comando crea un *worker* de la aplicación de Celery definido en el archivo de tasks. En este punto todo el backend de la aplicación web está funcionando dentro de la máquina. La base de datos esta configurada a partir del servicio RDS de AWS, por lo que no es necesario configurar nada de la base de datos.

Por otra parte, la instancia del frontend de la aplicación web se creo con la clase VistaFrontEnd, en este caso se usa el servidor web Ngnix, por lo que debemos tener instalado en la maquina en la que vamos a correr la aplicación web. Una vez Ngnix este correctamente instalado se debe configurar que la

aplicación de Flask, que en este caso contiene el frontend se ejecute con Ngnix. Para realizar esto se crea un archivo de configuración en el directorio *'/etc/nginx/sites-available'* y se modifica el contenido, con el comando *sudo nano configuracion.conf.* El contenido del archivo recién creado debe ser:

```
server {
    listen 80;
    server_name example.com;
    location / {
        proxy_pass http://localhost:5000;
        proxy_set_header Host $host;
        proxy_set_header X-Real-IP $remote_addr;
    }
    location /static{
        /Desarrollo-cloud-grupal/frontend/;
    }
}
```

Una vez se haya creado este archivo es necesario crear un enlace simbólico usando el comando *sudo ln -s /etc/nginx/sites-available/myapp.conf /etc/nginx/sites-enabled/* y por último reiniciar el Ngnix con *sudo systemctl restart nginx.*

4. Consideraciones para lograr la escalabilidad y conclusiones

La aplicación web que fue desarrollada en la entrega 1 es una aplicación distribuida en microservicios, lo cual presenta ventajas respecto a una aplicación monolítica. La base de datos esta desplegada en una instancia de RDS de AWS y la aplicación web de Flask esta desplegada en una instancia EC2 de AWS, esto presenta ciertas ventajas frente a la escalabilidad de una arquitectura monolítica. La escalabilidad de una aplicación web como esta se requiere para prestar un servicio que cumpla con las expectativas del usuario, y aumentar el numero de actividades realizadas.

Además de esto, se está realizando la tarea de compresión de archivos de manera asíncrona por medio de un worker de Celery, lo cual presenta ventajas en el backend de la aplicación que se ven reflejados en la interacción que tiene el usuario. Por ejemplo, el hecho de que la tarea de compresión sea asíncrona a la solicitud HTTP que genera el usuario, permite al usuario seguir haciendo uso de la aplicación web mientras se esta llevando a cabo la tarea de compresión de los archivos.

Esta aplicación web se desarrollo con una arquitectura de microservicios para poder facilitar su escalabilidad. Al implementarse una arquitectura de microservicios es posible escalar la aplicación web con mayor facilidad puesto que es posible replicar el servicio que no está cumpliendo con los requerimientos esperados de tiempo de espera, si la capacidad de la base de datos es deficiente para el trafico actual de solicitudes. Se debe evaluar cual es la expectativa de solicitudes realizadas al poner en funcionamiento la aplicación web, para poder determinar cuales deben ser las especificaciones de la instancia EC2 y RDS, una vez se hayan escogido las especificaciones se debe realizar una medición de las métricas de utilización de las instancias, y de cuantas solicitudes se están realizando, de manera que se puedan tomar decisiones frente a la necesidad de escalar las partes de la aplicación. Por ejemplo, se podría usar Grafana y Prometheus para revisar métricas como la utilización de la CPU de la instancia de EC2, el tiempo de respuesta de la aplicación y el numero de solicitudes que se están manejando.

Una arquitectura de microservicios permite a una aplicación web una mayor escalabilidad y a su vez, que una aplicación web pueda escalar fácilmente, permite que esta aplicación web cumpla con los servicios si se aumenta la cantidad de usuario o solicitudes que es generada. Asimismo, la arquitectura de microservicios ofrece la ventaja de tener una falla parcial en caso de que uno de los servicios falle. Por estas razones es que una arquitectura de microservicios es preferible en muchos casos al momento de escoger como debe ser desarrollada una aplicación web.

5. Enlaces:

La documentación realizada en Postman se puede encontrar en:
https://documenter.getpostman.com/view/13843294/2s93CPrY2y

El video de sustentación puede ser encontrado en el repositorio o en el siguiente vínculo:
https://youtu.be/hmUve_XsaHE